

Mini Project

Exploratory Data Analysis - Parfum Wanita di eBay

BENEDICTUS IRVANDA NUGROHO

[LINK](#)





BENEDICTUS IRVANDA NUGROHO
DATA ANALYST

LETS CONNECT



[Linkedin](#)



[GitHub](#)

EXPERIENCE

Fullstack Web Developer

Freelance 2025

Mobile Developer at Bangkit Academy (Google)

Intern – (Feb – Jun 2024)

EDUCATION



Informatika

2021 – 2025




Bootcamp Data Analytics

2026 – Now

Previous Projects

EXCEL DASHBOARD



- Menggunakan Pivot Tables, Advanced Formulas, dan VBA/Macros untuk otomatisasi laporan.
- Menampilkan visualisasi tren rekrutmen, tingkat perputaran karyawan (turnover rate), dan skor performa.

DATA PREPROCESSING



- Menggunakan library Pandas dan NumPy untuk menangani nilai yang hilang (missing values) dan data ganda (duplicates).
- Melakukan data cleaning pada teks deskripsi produk dan standarisasi format harga serta mata uang.
- Dampak: Menghasilkan dataset yang bersih dan terstruktur, mengurangi risiko bias atau error saat masuk ke tahap permodelan prediktif.

Table of Contents

Problem Statement

Data Understanding

Data Preparation

Visualisasi

Insight

Personal Reflection



Problem Statement



Industri parfum saat ini mengalami pertumbuhan sangat cepat, terutama melalui marketplace online seperti eBay. Konsumen memiliki banyak pilihan parfum dengan variasi:

- Brand,
- Type Parfum,
- Ukuran,
- Kategori Harga

Namun tidak semua produk parfum berhasil mendapatkan penjualan tinggi. Beberapa produk mampu menjadi best seller, sementara produk lainnya memiliki performa penjualan rendah meskipun berada pada marketplace yang sama

Karena itu, dilakukan exploratory data analysis untuk memahami karakteristik parfum yang paling diminati konsumen pada marketplace eBay, serta faktor-faktor yang berkontribusi terhadap tingginya penjualan dan revenue parfum wanita.

Sumber: Perfume Market Analysis



Data Understanding - About Dataset

Kolom	Deskripsi
brand	Merk dari parfum
title	judul produk pada daftar iklan
type	Jenis parfum (Eau de Parfum, Eau de Toilette, etc)
price	Harga parfum dalam angka
priceWithCurrency	Harga beserta simbol mata uang
available	Jumlah stok barang yang tersedia
availableText	Deskripsi tekstual mengenai ketersediaan produk
sold	Jumlah barang yang telah terjual
lastUpdated	Timestamp terakhir kali data iklan diperbarui
itemLocation	Lokasi fisik barang dikirim

Dataset ini merupakan data penjualan parfum wanita di eBay pada tahun 2024.

Didapatkan dengan metode web scrapping dari situs e-bay

Informasi Dataset

Baris : 1000 baris

Kolom : 10 kolom

Sumber : Dataset

Data Understanding - Import Data



01 Import library yang dibutuhkan (pandas)

02 Load dataset dari file CSV

03 Memanggil df.head(5) untuk melihat sekilas mengenai dataset nya

Dibawah ini merupakan 5 data teratas pada dataset

	brand	title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation
0	Carolina Herrera	Good Girl by Carolina Herrera 2.7 oz Eau De Pa...	Eau de Parfum	43.99	US \$43.99/ea	2.0	2 available / 393 sold	393.0	May 23, 2024 10:43:50 PDT	Thomasville, Alabama, United States
1	As Shown	Parfums de Marly Delina La Rosee Eau de Parfum...	Eau de Parfum	79.99	US \$79.99	5.0	5 available / 40 sold	40.0	May 24, 2024 00:15:48 PDT	New Jersey, Hong Kong
2	PRADA	PRADA Paradoxe by Prada EDP 3.0oz/90ml Spray P...	Eau de Parfum	59.99	US \$59.99	10.0	More than 10 available / 35 sold	35.0	May 14, 2024 20:54:25 PDT	Orange, New Jersey, United States
3	As Show	J'adore Parfum D'eau by Christian 3.4 oz EDP F...	Eau de Parfum	59.99	US \$59.99/ea	10.0	More than 10 available / 9 sold	9.0	May 23, 2024 01:23:05 PDT	USA, New Jersey, Hong Kong
4	Khadlaj	Shiyaaka for Men EDP Spray 100ML (3.4 FLOZ) B...	Eau de Parfum	29.99	US \$29.99/ea	10.0	More than 10 available	NaN	NaN	Little Ferry, New Jersey, United States

Data Understanding - Data Exploration



Melakukan data understanding untuk melihat kejanggalan data sebelum dilakukan nya proses cleaning

1. Terdapat missing value pada beberapa kolom yang menandakan perlunya handling missing value pada tahap data cleaning.
2. Pada beberapa kolom terdapat tipe data yang belum sesuai:
 - a. Available → Seharusnya integer
 - b. Sold → Seharusnya integer
 - c. lastUpdated → Seharusnya Datetime

Persentase Missing Values

brand	0.1
title	0.0
type	0.2
price	0.0
priceWithCurrency	0.0
available	13.1
availableText	0.8
sold	1.6
lastUpdated	7.3
itemLocation	0.0

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 10 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   brand                 999 non-null   object
 1   title                 1000 non-null  object
 2   type                  998 non-null   object
 3   price                 1000 non-null  float64
 4   priceWithCurrency     1000 non-null  object
 5   available              869 non-null   float64
 6   availableText          992 non-null   object
 7   sold                  984 non-null   float64
 8   lastUpdated           927 non-null   object
 9   itemLocation          1000 non-null  object
dtypes: float64(3), object(7)
memory usage: 78.3+ KB
```

Data Understanding - Data Exploration



1. Analisis kolom price:

- Ditemukan bahwa mean > median, yang mengindikasikan beberapa parfum yang sangat mahal menarik angka rata-rata ke atas.

2. Analisis kolom available:

- Ditemukan bahwa stok parfum berada pada kisaran nilai median (10), namun ada penjual yang memiliki stok hingga 557 unit

3. Analisis kolom sold:


- Terdapat produk yang terjual hingga 17 ribu unit sedangkan sebagian besar unit lainnya terjual dibawah 263 unit, yang dapat menyebabkan data tidak berdistribusi normal

	price	available	sold
count	1000.000000	869.000000	984.000000
mean	39.892980	21.426928	497.321138
std	29.072186	51.476703	1372.510561
min	1.990000	2.000000	1.000000
25%	20.700000	6.000000	15.000000
50%	32.990000	10.000000	52.000000
75%	49.990000	10.000000	263.750000
max	299.990000	557.000000	17854.000000

Data Understanding - Data Exploration



Histogram Kolom Numerik



- Mayoritas produk parfum berada pada rentang harga rendah hingga menengah
- Sebagian besar produk memiliki stok dan jumlah penjualan yang relatif rendah, namun terdapat beberapa produk dengan performa penjualan sangat tinggi sebagai outlier

	brand		title	type	price	priceWithCurrency	available	availableText	sold	lastUpdated	itemLocation
344	FLOWER	12 Piece Woman's Perfume Lot: Assorted scents ...	Perfume		48.0	US \$48.00	4.0	4 available / 1 sold	1.0	NaN	Webster, Florida, United States
662	FLOWER	12 Piece Woman's Perfume Lot: Assorted scents ...	Perfume		48.0	US \$48.00	4.0	4 available / 1 sold	1.0	NaN	Webster, Florida, United States

- Terdapat 1 data yang duplikat, yang mengindikasikan perlu adanya penghapusan data pada salah satu baris tersebut

Data Understanding - Data Exploration



Dataset Unique Values

column_name	n_unique	sample_unique_values
brand	247	[Carolina Herrera, As Shown, PRADA, As Show, Khadlaj, Viktor & Rolf, AS SHOW, Versace, Lattafa, Yves Saint Laurent]
title	975	[Good Girl by Carolina Herrera 2.7 oz Eau De Parfum Spray Women's New & Sealed, Parfums de Marly Delina La Rosee Eau de Parfum 2.5 Fl Oz/75ml Spray for Women, PRADA Paradoxe by Prada EDP 3.0oz/90ml Spray Perfume for Women New In Box, J'adore Parfum D'eau by Christian 3.4 oz EDP Fragrance for Women New In Box, Shiyaaka for Men EDP Spray 100ML (3.4 FLOZ) By Khadlaj (Woody, Aromatic, Earth), Flowerbomb by Viktor & Rolf 3.4 oz 100ML Eau De Parfum Brand New Sealed In Box, PRADA Paradoxe by Prada EDP 3.0oz/90ml Spray Perfume for Women New In Box US, Versace Bright Crystal Women EDT 6.7 oz 200 ml New Sealed in Box, Versace Bright Crystal by Versace for Women EDT Spray 3.0 oz / 90 ml New In Box, Fakhar by Lattafa Eau de Parfum 3.4 oz / 100 ml Spray for Men]
type	71	[Eau de Parfum, Eau de Toilette, Eau De Parfum, Spray, ~ BODY FIRM ADVANCED BODY REPAIR TREATMENT ~, Parfum, Fragrance Mist, Deodorant Stick, Gift Sets, Eau de Perfume]
priceWithCurrency	655	[US \$43.99/ea, US \$79.99, US \$59.99, US \$59.99/ea, US \$29.99/ea, US \$51.99/ea, US \$58.99, US \$52.79/ea, US \$29.99, US \$22.75/ea]
availableText	746	[2 available / 393 sold, 5 available / 40 sold, More than 10 available / 35 sold, More than 10 available / 9 sold, More than 10 available, 8 available / 184 sold, Out of Stock / 18 sold, 6 available / 258 sold, Last One / 251 sold, More than 10 available / 174 sold]
lastUpdated	911	[May 23, 2024 10:43:50 PDT, May 24, 2024 00:15:48 PDT, May 14, 2024 20:54:25 PDT, May 23, 2024 01:23:05 PDT, May 23, 2024 10:44:09 PDT, May 24, 2024 00:15:13 PDT, May 21, 2024 06:41:13 PDT, May 23, 2024 22:39:02 PDT, May 24, 2024 00:25:04 PDT, May 24, 2024 11:01:13 PDT]
itemLocation	299	[Thomasville, Alabama, United States, New Jersey, Hong Kong, Orange, New Jersey, United States, USA, New Jersey, Hong Kong, Little Ferry, New Jersey, United States, Warren, Michigan, United States, Astoria, New York, United States, Dexter, Michigan, United States, Jamaica, New York, United States, New York, New York, United States]




- Ditemukan inkonsistensi penulisan pada beberapa kolom kategorikal, khususnya pada kolom `type` dan `brand`, seperti:
 - `Eau de Parfum`, `Eau De Parfum`, dan `Eau de Perfume`
 - As Shown`, `AS SHOW`, dan `As Show`

Data Understanding - Data Exploration



Outlier Detection

```
Persentase outlier pada kolom price: 5.21%  
Persentase outlier pada kolom sold: 14.81%  
Persentase outlier pada kolom available: 11.71%
```



Angka ekstrim pada ketiga kolom ini bukanlah kesalahan input data, melainkan mencerminkan kondisi riil ecommerce. Dalam industri parfum, memang ada produk parfum mewah dengan harga yang sangat tinggi, kemudian juga ada parfum best seller yang memiliki stok melimpah

Data Understanding - Data Quality Issues



Validate Data Types

- Terdapat tipe data yang belum sesuai dengan kondisi aslinya
- Tipe data pada kolom available dan sold masih dalam bentuk float, hal ini belum tepat dikarenakan jumlah stok itu pasti selalu dalam bentuk bulat (integer)
- Tipe data pada kolom lastUpdated masih dalam bentuk object, perlu adanya konversi tipe data ke Datetime agar sistem dapat mengekstrak informasi tanggal/bulan/hari nya

Missing Value

- Terdapat missing value pada beberapa kolom: brand, type, available, sold, availableText, lastUpdated

Duplicate Data

- Terdapat 1 data yang duplikat

Inconsistency Data

- Ditemukan inkonsistensi penulisan (spelling) dan variasi penggunaan huruf kapital pada kolom brand dan type
- Contoh: Perbedaan penulisan antara "Eau de Parfum", "EDP", dan "Eau De Parfum" yang merujuk pada kategori yang sama

Outlier

- Outlier terdapat pada ketiga kolom numerik

Data Preparation - Data Cleaning



Data Mapping Kolom Type

- Menyederhanakan ratusan variasi penulisan tipe parfum menjadi 9 kategori utama untuk analisis yang lebih akurat.
- Proses:
 - Mengubah semua teks menjadi huruf kecil agar konsisten
 - Menggunakan teknik string matching untuk mencari kata kunci spesifik dalam tipe parfum

Before

```
array(['Eau de Parfum', 'Eau de Toilette', 'Eau De Parfum', 'Spray',  
      '~ BODY FIRM ADVANCED BODY REPAIR TREATMENT ~', 'Parfum',  
      'Fragrance Mist', 'Deodorant Stick', 'Gift Sets', 'Eau de Perfume',  
      'Eau de Cologne', '3 Pc', 'Eau de Parfum, Eau De Parfume',  
      'Body Spray', 'Extrait de Parfum', 'Mist',  
      'Eau de Toilette, Spray', 'Perfume', '/', 'Perfume, Eau de Parfum',  
      'Fragrances', 'Eau De Cologne', 'Hair Perfume',  
      'Eau de Parfum, Spray', 'Cream', 'Eau De Parfum 2 Pcs Set', 'EDT',  
      "L'Eau de Parfum", 'Eau de Parfume', "L'eau de Parfum",  
      'SKIN_MOISTURIZER', 'EDP and Parfum', 'Fine Fragrance Mist',  
      'Anti-Aging Body Cream', 'Body Lotion', 'Body Oil', 'Body Lotion', 'Body Oil']
```

65 nilai unik

After

```
array(['Eau de Parfum', 'Eau de Toilette', 'Others', 'Body Care',  
      'Gift Set', 'Cologne', 'Extrait de Parfum', 'Body Mist', 'Unknown'],  
      dtype=object)
```

9 nilai unik

Data Preparation - Data Cleaning



Data Mapping Kolom Brand

- Proses nya sama seperti pada kolom type, yaitu mapping untuk menyederhanakan penulisan brand parfum

Before (235 unique Brand)

```
array(['Carolina Herrera', 'As Shown', 'Prada', 'As Show', 'Khadlaj',  
      'Viktor & Rolf', 'Versace', 'Lattafa', 'Yves Saint Laurent',  
      'Gucci', 'Coach', 'Guerlain', 'Philosophy', 'Marc Jacobs',  
      'Dolce & Gabbana', 'Qrc', '~ Crepe Erase ~', 'Unbranded', 'Ysl',  
      'Parfums De Marly', 'Dolce&Gabbana', 'Ex Nihilo',  
      'Juliette Has A Gun', 'Davidoff', 'Giorgi^O Armani', 'Roja',  
      'Ariana Grande', 'Sol De Janeiro', 'Kilian', 'Donna Karan',  
      'Narciso Rodriguez', 'Giorgio^2 Armani', 'Kenzo', 'Burberry',  
      'Thierry Mugler', 'Juicy Couture', 'Maison Margiela', 'Jo Malone',  
      'Elizabeth Arden', 'Urban Outfitters', 'Dossier',  
      'Maison Alhambra', 'Alt Fragrances', 'Estée Lauder',  
      "Victoria'S Secret", 'Kim Kardashian', 'Gap', 'Cacharel',  
      'Jessica McClintock', 'As Shown', 'Clinique', 'Valentino',  
      'Giorgio Armani', 'Jimmy Choo', 'Calvin Klein', 'Alfred Sung',  
      'Gloria Vanderbilt', 'Parfums', 'Ouai', 'Lancôme',
```

235 → 211

```
1 # mengecek jumlah unique setelah dicleaning  
2 df_clean_2['brand'].nunique()  
✓ 0.0s  
211
```

Duplicate Data

- Menghapus baris data yang duplikat, simpan salah satu data nya saja

```
df_dup = df_dup.drop_duplicates(keep='first')
```



```
1 df_dup.duplicated().sum()  
✓ 0.0s  
np.int64(0)
```

Data Preparation - Data Cleaning



Penanganan Missing Value

1. Kolom lastUpdated

- Terdapat 72 data kosong pada kolom lastUpdated (Waktu pembaruan terakhir listing).
- Mengisi missing values menggunakan tanggal dan jam yang paling sering muncul dalam dataset. (Mode)

2. Kolom Sold

- Terdapat 16 missing value pada kolom sold
- Mengisi missing value tersebut dengan 0
- Ditemukan bahwa 16 data tersebut tidak memiliki informasi pada ketiga kolom yang mengindikasikan bahwa listing tersebut masih baru atau memang belum pernah terjual sejak dipublikasikan

3. Kolom available

- Kolom available memiliki missing values. Namun, kolom pendukung availableText berisi informasi tekstual yang bisa digunakan untuk memulihkan data yang hilang tersebut.
- Dilakukan pengisian missing values dengan logika kondisional:
 - Jika availableText mengandung kata "out of stock", maka nilai available diisi 0.
 - Jika availableText mengandung kata "last one", maka nilai available diisi 1
 - Sisa data yang masih kosong dan tidak memiliki kata kunci di atas diisi menggunakan nilai Median.



available	availableText	sold
10.0	More than 10 available	NaN
10.0	More than 10 available	NaN
2.0	2 available	NaN
NaN	NaN	NaN



available	availableText
NaN	Out of Stock / 18 sold
NaN	Last One / 251 sold
NaN	Last One / 43 sold

Data Preparation - Data Cleaning



Validasi Kolom price dengan priceWithCurrency

- Memastikan konsistensi nilai antara kolom numerik price dengan kolom referensi asli priceWithCurrency
- Memeriksa apakah angka pada kolom price (hasil ekstraksi/pembersihan) termuat di dalam string kolom priceWithCurrency
- Hasil → ditemukan bahwa harga pada kolom price sama dengan harga pada kolom priceWithCurrency. Oleh karena itu kolom priceWithCurrency akan di drop/hapus

Contoh

price	priceWithCurrency
29.99	US \$29.99

Hasil

Apakah semua data sama?	
True	999

Data Preparation - Data Cleaning



Hasil Akhir Dataset/Dataframe setelah proses cleaning :

```
<class 'pandas.core.frame.DataFrame'>
Index: 999 entries, 0 to 999
Data columns (total 9 columns):
 #   Column          Non-Null Count  Dtype
---  -
 0   brand           999 non-null    object
 1   title           999 non-null    object
 2   type            999 non-null    object
 3   price           999 non-null    float64
 4   available        999 non-null    float64
 5   availableText    991 non-null    object
 6   sold            999 non-null    float64
 7   lastUpdated     999 non-null    object
 8   itemLocation    999 non-null    object
dtypes: float64(3), object(6)
memory usage: 110.3+ KB
```

Notes: Kolom availableText akan didrop pada data Manipulation

Dihapus karena informasi data pada available text sudah terpenuhi dan tervalidasi ke dalam kolom available dan sold




Data Preparation - Data Cleaning



Deteksi Outlier - Visual & IQR

Dalam dataset ini, identifikasi outlier dilakukan menggunakan metode Interquartile Range (IQR) untuk melihat persebaran data pada kolom-kolom numerik utama.

```
Persentase outlier pada kolom price: 5.21%  
Persentase outlier pada kolom sold: 14.81%  
Persentase outlier pada kolom available: 11.71%
```



Data Preparation - Data Cleaning



Deteksi Outlier

Meskipun ditemukan persentase outlier yang cukup signifikan, khususnya pada kolom Sold dan Available, diputuskan untuk tetap mempertahankan data tersebut tanpa melakukan penghapusan (deletion) atau pembatasan (capping).

- Penerapan capping akan merusak nilai asli dari produk parfum mewah yang secara alami memiliki harga tinggi.
- Jika didelete, maka kita akan kehilangan banyak data penting

Angka ekstrim pada ketiga kolom ini bukanlah kesalahan input data, melainkan mencerminkan kondisi riil ecommerce. Dalam industri parfum, memang ada produk parfum mewah dengan harga yang sangat tinggi, kemudian juga ada parfum best seller yang memiliki stok melimpah

Data Preparation - Data Manipulation



Uji Normalitas

- Uji Shapiro-Wilk digunakan untuk menguji apakah distribusi normal.
- Uji ini merupakan standar dalam analisis statistika untuk menentukan apakah data dapat diolah dengan metode Parametrik (seperti ANOVA) atau harus menggunakan metode Non-Parametrik (seperti Kruskal-Wallis).

Temuan

- Karena nilai p-value < 0.05 , Hal ini membuktikan bahwa distribusi data ketiga kolom menyimpang secara nyata dari distribusi normal
- Perlu dilakukan pengujian untuk transformasi data/normalisasi data

```
=== Uji Normalitas Kolom: price ===
Statistik Uji: 0.7672
P-Value      : 0.0000000000
Hasil        : Data TIDAK berdistribusi Normal
-----
=== Uji Normalitas Kolom: sold ===
Statistik Uji: 0.3818
P-Value      : 0.0000000000
Hasil        : Data TIDAK berdistribusi Normal
-----
=== Uji Normalitas Kolom: available ===
Statistik Uji: 0.3261
P-Value      : 0.0000000000
Hasil        : Data TIDAK berdistribusi Normal
-----
```

Data Preparation - Data Manipulation



Upaya Normalitas Data

- Melakukan transformasi matematika pada data asli untuk menarik nilai-nilai ekstrem (outlier) agar distribusi data mendekati distribusi normal (lonceng), sehingga memenuhi asumsi pengujian statistik parametrik.
- Metode yang dipakai:
 - Log: mengubah data asli menjadi nilai logaritma nya
 - Square Root: setiap nilai dalam dataset digantikan dengan akar kuadrat dari nilai tersebut
 - Boxcox: Metode otomatis yang mencari nilai pangkat / lambda paling optimal untuk menormalkan distribusi data.

Kolom	Sqrt	Log	Boxcox
Price	0.000	0.040	0.053
Sold	0.000	0.000	0.000
Available	0.000	0.000	0.000

Temuan

- Kolom price berhasil mencapai distribusi normal melalui Box-Cox ($P > 0.05$). Data ini siap diolah dengan metode statistik standar.
- Kolom sold dan available meskipun telah melalui 3 metode yang berbeda, namun p-value masih dibawah 0.05

Data Preparation - Data Manipulation



Mengubah Data Type

- Mengubah tipe data kolom sold yang mulanya float menjadi integer
- Mengubah tipe data kolom available yang mulanya float menjadi integer
- Mengubah tipe data kolom lastUpdated yang mulanya object menjadi datetime

#	Column	Non-Null	Count	Dtype
0	brand	999	non-null	object
1	title	999	non-null	object
2	type	999	non-null	object
3	price	999	non-null	float64
4	available	999	non-null	int64
5	availableText	991	non-null	object
6	sold	999	non-null	int64
7	lastUpdated	999	non-null	datetime64[ns]
8	itemLocation	999	non-null	object

Data Preparation - Data Manipulation



Feature Engineering - revenue

- Menambahkan kolom baru revenue yang didapatkan dari hasil perkalian kolom price dan kolom sold

revenue

17288.07

Feature Engineering - lokasi penjual

- Kolom itemLocation berisi teks alamat yang tidak seragam (contoh: "Thomasville, Alabama, United States"). Informasi ini perlu dipecah agar kita bisa menganalisis pengaruh letak geografis terhadap harga dan penjualan.
- Kota - State - Negara
- Saya melakukan pemisahan teks yang bertujuan:
 - Mengambil informasi terakhir untuk mengetahui negara asal pengiriman
 - Mengambil informasi teks kedua terakhir untuk mengetahui negara bagian/provinsi nya

country state

United States Alabama

Feature Engineering - Ukuran Parfum (ml)

- Mengekstrak ukuran parfum dari kolom title dalam satuan mililiter

size_ml

80.0

Feature Engineering - price_category

- Membuat kolom baru untuk membuat kategori harga parfum
 - 0 - 30 → Budget
 - 31 - 80 → Midrange
 - 81 - 150 → Prestige
 - > 150 → Luxury

price_category

Luxury

Data Preparation - Data Manipulation

Encoding Kolom Kategorikal

- One Hot Encoding
 - Untuk kolom type dan country
 - Digunakan untuk kolom dengan jumlah kategori sedikit.
 - Menciptakan kolom baru untuk setiap kategori agar semua dianggap setara tanpa ada urutan tertentu.
- Binary Encoding
 - Untuk kolom brand (211 unique)
 - Digunakan untuk kolom dengan ratusan kategori (seperti merk parfum).
 - Meringkas data menjadi kode biner agar dataset tidak terlalu "lebar" namun tetap menjaga informasi keunikan tiap brand.
- Ordinal Encoding
 - Untuk kolom price category
 - Menggunakan ordinal dikarenakan memiliki urutan / jenjang kategori



	oh_type_Body Care	oh_type_Body Mist	oh_type_Cologne	oh_type_Eau de Parfum	oh_type_Eau de Toilette	oh_type_Extrait de Parfum
0	0	0	0	1	0	0
1	0	0	0	1	0	0
2	0	0	0	1	0	0

Before cleaning & manipulation

```
Data columns (total 12 columns):
#      Column      Non-Null Count  Dtype
---  -
0     brand        999 non-null     object
1     title         999 non-null     object
2     type          999 non-null     object
3     price         999 non-null     float64
4     available     999 non-null     int64
5     availableText  991 non-null     object
6     sold          999 non-null     int64
7     lastUpdated   999 non-null     datetime64[ns]
8     itemLocation  999 non-null     object
9     sold_log      999 non-null     float64
10    available_log  999 non-null     float64
11    price_boxcox   999 non-null     float64
```

	price	available	sold
count	1000.000000	869.000000	984.000000
mean	39.892980	21.426928	497.321138
std	29.072186	51.476703	1372.510561
min	1.990000	2.000000	1.000000
25%	20.700000	6.000000	15.000000
50%	32.990000	10.000000	52.000000
75%	49.990000	10.000000	263.750000
max	299.990000	557.000000	17854.000000

After cleaning & manipulation

```
Data columns (total 10 columns):
#      Column      Non-Null Count  Dtype
---  -
0     brand        998 non-null     object
1     title         998 non-null     object
2     type          998 non-null     object
3     price         998 non-null     float64
4     available     998 non-null     int64
5     sold          998 non-null     int64
6     revenue       998 non-null     float64
7     country       998 non-null     object
8     size_ml       998 non-null     float64
9     price_category 998 non-null     object
```

	price	available	sold	revenue	size_ml
count	998.000000	998.000000	998.000000	998.000000	998.000000
mean	39.859709	19.286573	490.338677	13915.549128	83.433868
std	29.089323	48.378606	1364.097893	37036.017452	42.785640
min	1.990000	0.000000	0.000000	0.000000	1.000000
25%	20.680000	5.000000	14.000000	520.485000	74.000000
50%	32.990000	10.000000	51.000000	1752.050000	100.000000
75%	49.990000	10.000000	257.500000	8240.115000	101.000000
max	299.990000	557.000000	17854.000000	475987.640000	473.000000

Data Sample



Mengambil sampel secara acak, mengambil 10 % dari populasi

Df_sample

	price	available	sold	revenue	size_ml
count	100.000000	100.000000	100.000000	100.000000	100.000000
mean	38.126800	17.480000	310.190000	10340.811600	80.230000
std	25.143938	40.948719	788.142269	28392.693647	42.913315
min	9.890000	1.000000	0.000000	0.000000	1.000000
25%	20.367500	4.000000	10.000000	327.500000	50.000000
50%	32.595000	9.000000	37.000000	945.510000	93.000000
75%	49.247500	10.000000	143.500000	5211.667500	101.000000
max	150.000000	300.000000	4936.000000	198400.020000	237.000000

Df_population


	price	available	sold	revenue	size_ml
count	998.000000	998.000000	998.000000	998.000000	998.000000
mean	39.859709	19.286573	490.338677	13915.549128	83.433868
std	29.089323	48.378606	1364.097893	37036.017452	42.785640
min	1.990000	0.000000	0.000000	0.000000	1.000000
25%	20.680000	5.000000	14.000000	520.485000	74.000000
50%	32.990000	10.000000	51.000000	1752.050000	100.000000
75%	49.990000	10.000000	257.500000	8240.115000	101.000000
max	299.990000	557.000000	17854.000000	475987.640000	473.000000

Nilai-nilai statistik utama (seperti Mean, Median, dan kaurtil antara sampel (100 data) dan populasi (998 data) menunjukkan angka yang sangat mirip dan berdekatan. Ini membuktikan bahwa karakteristik sampel sudah mampu mewakili populasi aslinya tanpa ada bias yang merusak data.

Data Distribution - Encoding



Distribusi Kolom Hasil Encoding




Uji Normalitas Shapiro

	Kolom	Statistik Uji	P-Value	Hasil
0	oe_price_category	0.7530	3.888754e-36	TIDAK Normal
1	oh_type_Eau de Parfum	0.5527	1.240806e-44	TIDAK Normal
2	oh_type_Eau de Toilette	0.4835	7.816119e-47	TIDAK Normal
3	oh_type_Cologne	0.1968	6.327933e-54	TIDAK Normal
4	oh_type_Body Mist	0.0357	5.170621e-57	TIDAK Normal
5	oh_type_Gift Set	0.0549	1.145810e-56	TIDAK Normal
6	be_brand_0	0.3577	2.874284e-50	TIDAK Normal
7	be_brand_1	0.5052	3.592526e-46	TIDAK Normal
8	be_brand_2	0.6102	1.401182e-42	TIDAK Normal

Berdasarkan hasil uji normalitas:

- Setiap kolom yang diuji memiliki nilai P-Value yang jauh di bawah ambang batas
- Distribusi data tidak normal

Visualization Output




Karakteristik Produk pada Top Brand

brand	type	price_category	Total_Sold
Calvin Klein	Eau de Parfum	Budget	36874
Versace	Eau de Toilette	Budget	14147
Versace	Eau de Parfum	Midrange	11583
Dolce & Gabbana	Eau de Toilette	Midrange	11013
Versace	Eau de Toilette	Midrange	8159
Calvin Klein	Eau de Parfum	Midrange	7018

- Calvin Klein, Versace, dan Dolce & Gabbana menjadi brand dengan jumlah penjualan tertinggi pada dataset parfum marketplace.
- Selanjutnya dilakukan analisis untuk mengidentifikasi karakteristik produk yang membuat brand-brand tersebut memiliki performa penjualan tinggi.
- Top brand didominasi oleh tipe Eau de Parfum dan Eau de Toilette dengan kategori harga Budget hingga Midrange.
- Hal ini menunjukkan bahwa kombinasi antara tipe parfum populer dan harga yang relatif terjangkau menjadi faktor utama tingginya penjualan produk parfum.

Visualization Output

Hubungan antara Harga Produk dan Jumlah Terjual



- Sebagian besar produk dengan harga rendah hingga menengah memiliki jumlah penjualan lebih tinggi
- Semakin tinggi harga produk, volume penjualan cenderung menurun
- Beberapa produk dengan harga menengah memiliki penjualan yang tinggi

Uji Hipotesis

- Menggunakan Kruskal-wallis dikarenakan data tidak berdistribusi normal
- Untuk menganalisa **Pengaruh Kategori Harga terhadap Jumlah Penjualan Produk Parfum**
 - H_0 : Tidak terdapat perbedaan signifikan jumlah penjualan antar kategori harga parfum.
 - H_1 : Terdapat perbedaan signifikan jumlah penjualan antar kategori harga parfum.


Hasil

Statistic: 40.97376909485162
P-Value: 6.623508936740061e-09

- Karena $p\text{-value} < 0.05$, maka terdapat perbedaan signifikan jumlah penjualan antar kategori harga parfum.
- Hasil ini memperkuat temuan EDA bahwa produk Budget dan Midrange memiliki performa penjualan yang lebih baik dibanding produk premium.


Visualization Output

Distribusi Kategori Harga pada Produk High Revenue




- Mayoritas produk dengan revenue tertinggi berasal dari kategori budget dan midrange, sedangkan kategori prestige hanya memiliki sedikit produk dengan high revenue
- Hal ini menunjukkan bahwa revenue tinggi tidak selalu berasal dari produk premium, tetapi lebih dipengaruhi oleh produk segmen dengan harga terjangkau

Distribusi Jumlah Produk Berdasarkan Kategori Harga



- Pasar parfum wanita di platform ini dikuasai sepenuhnya oleh kategori Budget dan midrange
- Jumlah produk di kelas prestige dan luxury sangat sedikit. Ini menunjukkan bahwa platform eBay ini tidak menjadi pilihan utama bagi penjual untuk memasarkan parfum kelas mewah


Visualization Output




- Ukuran didominasi oleh botol 101 ml
- Terdapat ukuran yang mirip seperti 98 ml dan 100 ml. Perbedaan kecil ini terjadi karena variasi penulisan teks judul oleh penjual saat mengonversi satuan Ounce (oz) ke Mililiter (ml), yang secara praktis merujuk pada kategori produk botol besar yang sama.
- Temuan menarik adalah banyak customer yang membeli 5ml, hal ini menunjukkan ada segmen konsumen yang aktif membeli sampel kecil untuk mencoba aroma sebelum berkomitmen membeli botol penuh yang mahal



Visualization Output




- Distribusi terlihat right skewed, di mana hanya sedikit produk dengan ukuran sangat besar. Hal ini menunjukkan ukuran standar masih menjadi preferensi utama pasar
- Terdapat aktivitas inventori kecil (sampel 5ml) untuk memfasilitasi konsumen yang ragu sebelum membeli botol penuh.




- Terjadi lonjakan penjualan vertikal yang masif tepat di garis 100 ml. Produk super best-seller toko terkonsentrasi di ukuran ini dengan rekor penjualan menembus 15.000 hingga 17.500+ botol.
- Ukuran ini sangat populer karena menawarkan harga lebih hemat untuk penggunaan jangka panjang

Visualization Output




- Tipe Eau de Parfum menghasilkan total revenue tertinggi secara signifikan dibanding tipe parfum lainnya. Hal ini menunjukkan bahwa tipe parfum ini tidak hanya mendominasi jumlah produk, tetapi juga memberikan kontribusi terbesar terhadap pendapatan.
- Tipe Eau de Toilette berada di posisi kedua dengan revenue yang masih cukup tinggi, sedangkan tipe lain memiliki kontribusi revenue yang relatif kecil dan cenderung menjadi segmen niche dalam dataset.



- Distribusi produk parfum didominasi oleh tipe Eau de Parfum dengan jumlah yang jauh lebih tinggi dibanding tipe lainnya. Hal ini menunjukkan bahwa mayoritas brand lebih berfokus pada parfum dengan aroma lebih kuat dan tahan lama.
- Tipe Eau de Toilette berada di posisi kedua, sedangkan kategori lain seperti Cologne, Body Mist, dan Gift Set memiliki jumlah produk yang relatif sedikit dan cenderung menjadi niche market.

Visualization Output



- **Korelasi Revenue & Sold:**

- Korelasi positif yang sangat kuat antara sold dan revenue (0.92). Semakin banyak unit terjual, total pendapatan cenderung naik

- **Korelasi Price & Sold:**

- Korelasi negatif lemah (-0.18). Kecenderungannya adalah semakin mahal harga parfum, semakin sedikit yang terjual


- **Korelasi size_ml & Price:**

- Korelasi positif sangat lemah (0.16). Meskipun ada kecenderungan kecil bahwa parfum berukuran lebih besar dijual lebih mahal, namun korelasinya sangat lemah sehingga bukan penentu utama

- **Korelasi available & sold:**

- Korelasi positif lemah (0.23). seller yang sejak awal memasang stok besar cenderung memiliki total sold lebih tinggi

Visualization Output



- **Hubungan sold vs revenue (baris 3 kolom 2)**
 - Pola garis lurus (linear positif)
 - Setiap ada kenaikan jumlah produk yang terjual, pendapatan toko cenderung akan ikut naik
- **Hubungan price vs sold (baris 2 kolom 1)**
 - Mayoritas produk terkonsentrasi di harga rendah dengan jumlah sold bervariasi hingga banyak, sementara produk mahal hampir semuanya memiliki sold yang rendah

Visualization Output



Temuan Tambahan

- Dilakukan filtering untuk mengidentifikasi produk dengan penjualan tinggi namun stok menipis, sehingga berpotensi mengalami kehabisan stok

Kriteria

- Sold tinggi : > 258 botol → Mengambil top 25% produk penjualan tertinggi sebagai indikator “laris”
- Stok menipis : ≤ 5 botol → Mengambil bottom 25% sisa stok terkecil sebagai indikator “stok kritis”
- Produk kritis: 24 produk

brand		title	sold	available	price	revenue
Carolina Herrera	Good Girl by Carolina Herrera 2.7 oz Eau De Parfum Spray Women's New & Sealed		393	2	43.99	17288.07
Viktor & Rolf	Viktor Rolf Flowerbomb 3.4 oz L'Eau De Parfum Spray New Factory Sealed in Box		406	4	42.00	17052.00
Viktor & Rolf	Flowerbomb by Viktor & Rolf 3.4 oz L'Eau de Parfum Spray Factory Sealed New		404	4	42.00	16968.00
Juliette Has A Gun	Not a Perfume by Juliette Has A Gun, 3.3 oz EDP Spray for Women Eau De Parfum		288	2	49.99	14397.12
Narciso Rodriguez	Narciso Rodriguez for Her 3.3 fl oz / 100 ml EDP New Sealed Free Shipping		266	4	31.00	8246.00

Disarankan untuk memprioritaskan restock pada produk dengan volume penjualan tinggi agar ketersediaan stok tetap terjaga dan potensi kehilangan penjualan dapat diminimalkan.

Insight & Suggestion

Key Insights



Customer marketplace cenderung lebih menyukai tipe Eau de Parfum karena memiliki **ketahanan aroma** lebih lama dibanding tipe



Mayoritas konsumen lebih tertarik pada parfum dengan **harga terjangkau hingga menengah** karena memberikan keseimbangan antara harga dan kualitas produk




Parfum yang laris cenderung memiliki kombinasi:

- **Tipe parfum populer**
- **Harga terjangkau**




Recommendation



Seller dapat memprioritaskan produk dengan karakteristik yang paling sesuai dengan preferensi pasar, yaitu:

- **Tipe Eau de Parfum**
- Kategori harga **Budget - Midrange**
- Serta ukuran parfum standar yang paling banyak diminati konsumen . (**sekitar 100ml**)




Produk best seller dengan stok menipis perlu dipantau secara aktif **agar tidak kehabisan stok**



Insight & Suggestion




Recommendation



Untuk produk yang kurang laku, dapat menerapkan strategi menjual sampel 5-10ml dengan harga terjangkau untuk membangun kepercayaan pembeli

Referensi:

<https://freeyourself.com/blogs/news/ecommerce-perfume-sales-growth>



Produk premium kurang optimal dijual di marketplace karena konsumen cenderung ingin mencoba aroma secara langsung sebelum membeli. Seller disarankan mempertimbangkan penjualan melalui offline retail sebagai saluran utama, sementara eBay digunakan untuk promosi atau clearance stock saja.

Referensi:

<https://www.grandviewresearch.com/industry-analysis/perfume-market>

Dataset Reflection

- ✿ Kualitas data yang kurang baik (missing-values , duplikat, inkonsistensi data)
- ✿ Dataset hanya berasal dari marketplace eBay sehingga belum merepresentasikan seluruh pasar parfum.
- ✿ Data belum mencakup tren waktu penjualan

